Міністерство освіти і науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Інститут прикладного системного аналізу
Кафедра математичних методів системного аналізу

ЗВІТ

про виконання лабораторної роботи №2
з дисципліни «Інтелектуальний аналіз даних»

Виконала:

Студентка III курсу
Групи КА-76
Хиленко В.В.

Перевірила:
Недашківська Н.І.

Київ – 2020

Класифікація за допомогою бібліотеки Scikit-Learn Python

Постановка завдання (Варіант 17)

Побудувати моделі класифікації на основі методу опорних векторів:

- Моделі NuSVC(kernel="poly"). Розглянути різні комбінації гіперпараметрів nu, degree, coef0 - управляє тим, наскільки сильно поліноми високого ступеня впливають на модель порівняно з поліномами низького ступеня.
- Моделі SVC з різними ядрами та зваженими класами для випадку незбалансованих даних (параметр class_weight).
- Побудувати границі рішень графічно для кожної з моделей.
- Вивести значення опорних векторів (атрибут support*vectors*) для моделей.
- Настроїти гіперпараметри nu, degree, C за допомогою перехресної перевірки.
- Настроїти гіперпараметр probability за допомогою перехресної перевірки.

In [2]:
```python
import numpy as np
```

In [3]:
```python
from sklearn.datasets import make_blobs
n_samples_1 = 1000
n_samples_2 = 100
centers = [[0.0 , 0.0] , [2.0, 2.0]]
clusters_std = [1.5, 0.5]
X1, Y1 = make_blobs(n_samples=[n_samples_1, n_samples_2],        # gener
ate 2d classification dataset
        centers=centers,
        cluster_std=clusters_std,
        random_state=0, shuffle=False)


from sklearn.datasets import load_wine
X2, Y2 = load_wine(return_X_y=True)
```

1. Представити початкові дані графічно.

In [5]:
```python
%matplotlib inline
import seaborn as sns
import pandas as pd
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
```

make_blobs

In [6]:
```python
df1 = pd.DataFrame(X1)
df1['y'] = Y1.astype("int")
sns.pairplot(df1, hue='y')
```

Out[6]:
```
<seaborn.axisgrid.PairGrid at 0x7f67a1b06518>
```

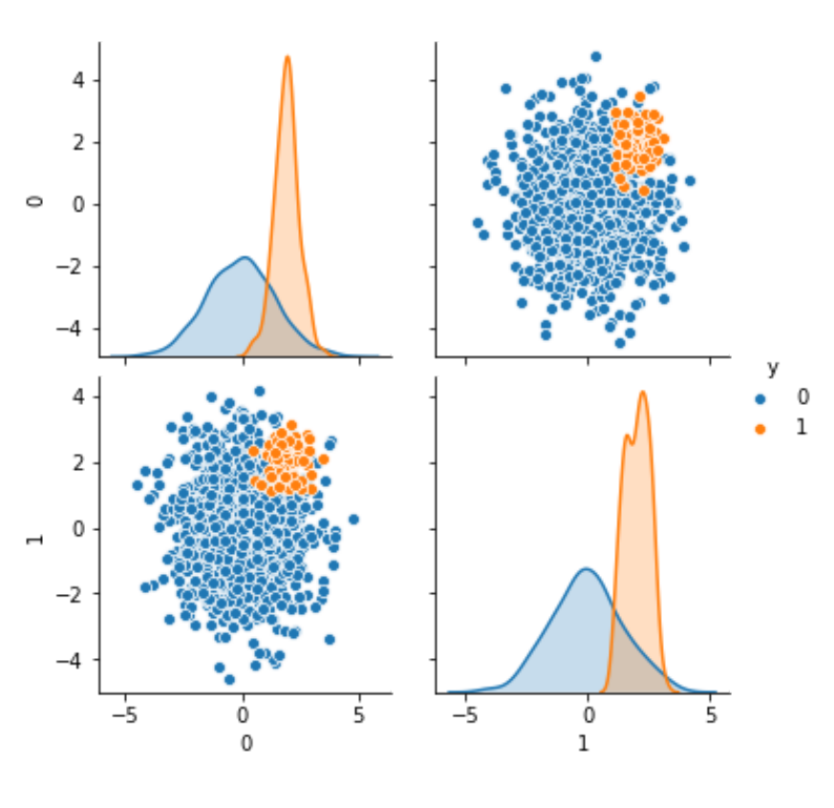

load_wine

In [7]:
```python
raw_data = load_wine()
features = pd.DataFrame(data=raw_data['data'],columns=raw_data['feature_
names'])
data = features
data.head()
```

Out[7]:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid
0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	
1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	
2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	
3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	
4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	

Теплокарта кореляцій між ознаками

Квадрати з додатніми величинами показують кореляцію між ознаками. Чим більша величина, тим сильніше відношення.

In [8]:
```python
correlation = data.corr()
plt.figure(figsize=(14, 12))
heatmap = sns.heatmap(correlation, annot=True, linewidths=0, vmin=-1)
```

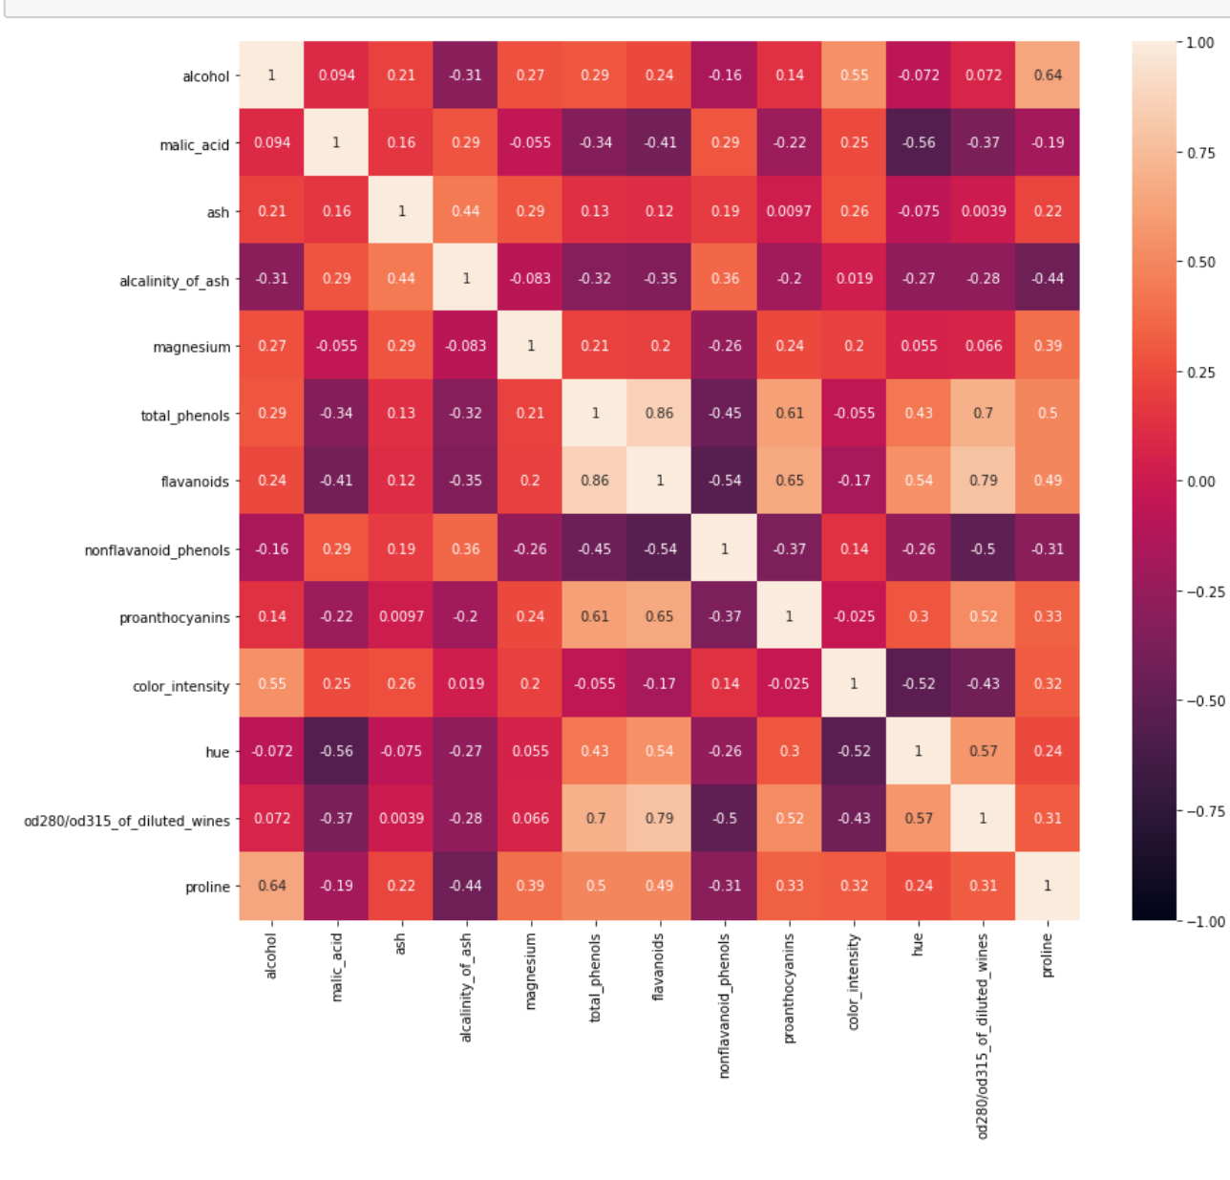

2. Розбити дані на навчальний і перевірочний набори.

In [9]:
```python
X1_train, X1_test, y1_train, y1_test = train_test_split(X1, Y1, test_siz
e=0.2, random_state=42)
X2_train, X2_test, y2_train, y2_test = train_test_split(X2, Y2, test_siz
e=0.2, random_state=42)
```

3-8. Побудувати моделі класифікації або регресії згідно з варіантом та

- Представити моделі графічно.
- Виконати прогнози на основі моделей.
- Для кожної з моделей оцінити, чи має місце перенавчання.
- Розрахувати додаткові результати моделей, наприклад, апостеріорні імовірності, опорні вектори або інші (згідно з варіантом).
- Для задач класифікації розрахувати критерії якості для кожної моделі:
  - матрицю неточностей (confusion matrix),
  - точність (precision),
  - повноту (recall),
  - міру F1 (F1 score),
  - побудувати криву точності-повноти (precision-recall (PR) curve), ROCкриву, показник AUC.

In [10]:
```python
from sklearn.svm import NuSVC, SVC
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import confusion_matrix, f1_score, precision_score,
recall_score, roc_curve, roc_auc_score, precision_recall_curve
```

make_blobs dataset

In [11]:
```python
def metrics1(true, predict, probs):
    #критерії якості для кожної моделі
    print("Confusion Matrix:\n", confusion_matrix(true, predict))
    print("Precision score: ", precision_score(true, predict))
    print("Recall score: ", recall_score(true, predict))
    print("F1 score: ", f1_score(true, predict))

    probs = probs[:, 1]
    fpr, tpr, thresholds = roc_curve(true, probs)
    auc = roc_auc_score(true, probs)
    print(f"AUC score: {auc}")
    # ROC curve
    plt.plot(fpr, tpr)
    plt.title("ROC Curve")
    plt.xlabel('False Positive Rate')
    plt.ylabel('True Positive Rate')
    plt.show()

    # PR Curve
    precision, recall, _ = precision_recall_curve(true, probs)
    plt.plot(recall, precision)
    plt.title("PR Curve")
    plt.xlabel('Recall')
    plt.ylabel('Precision')
    plt.show()
```

In [12]:
```python
def overfitting(clf, X_train, y_train, X_test, y_test):
    clf.fit(X_train, y_train)
    train_f1 = f1_score(y_train, clf.predict(X_train))
    test_f1 = f1_score(y_test, clf.predict(X_test))

    if train_f1 > test_f1:
        print(f"Overfitting {train_f1} >{test_f1}")
    else:
        print(f"Underfitting, {train_f1} < {test_f1}")
```

In [13]:
```python
def plot_dec(X, y, clf, print_vectors=False):
    h = .02  # step size in the mesh

    # we create an instance of SVM and fit out data. We do not scale our
    # data since we want to plot the support vectors

    # create a mesh to plot in
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                         np.arange(y_min, y_max, h))


    clf.fit(X, y)
    # Plot the decision boundary. For that, we will assign a color to ea
ch
    # point in the mesh [x_min, x_max]x[y_min, y_max].
    plt.subplot(2, 2, 1)
    plt.subplots_adjust(wspace=0.4, hspace=0.4)

    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])

    # Put the result into a color plot
    Z = Z.reshape(xx.shape)
    plt.contourf(xx, yy, Z, alpha=0.8)

    # Plot also the training points
    plt.scatter(X[:, 0], X[:, 1], c=y)
    plt.xlabel('x1')
    plt.ylabel('x2')
    plt.xlim(xx.min(), xx.max())
    plt.ylim(yy.min(), yy.max())
    plt.xticks(())
    plt.yticks(())
    plt.show()
    if print_vectors:
        try:
            print(clf.support_vectors_)
        except:
            pass
```

make_blobs dataset NuSVC

In [14]:
```python
for nu in np.arange(0, 1, 0.1):
     clf = NuSVC(nu=nu, kernel="poly", probability = True, degree = 3)
     try:
         clf.fit(X1_train, y1_train)
     except ValueError as e:
         print("nu {} not feasible".format(nu))
```

```
nu 0.0 not feasible
nu 0.2 not feasible
nu 0.30000000000000004 not feasible
nu 0.4 not feasible
nu 0.5 not feasible
nu 0.6000000000000001 not feasible
nu 0.7000000000000001 not feasible
nu 0.8 not feasible
nu 0.9 not feasible
```

In [15]:
```python
clf = NuSVC(nu=0.1, kernel="poly", probability = True, degree = 3)
clf.fit(X1_train, y1_train)
metrics1(y1_test, clf.predict(X1_test), probs=clf.predict_proba(X1_test
))
overfitting(clf, X1_train, y1_train, X1_test, y1_test)
plot_dec(X1, Y1, clf, print_vectors=False)
```

```
Confusion Matrix:
 [[193  11]
 [  0  16]]
Precision score:  0.5925925925925926
Recall score:  1.0
F1 score:  0.7441860465116279
AUC score: 0.9810049019607844
```

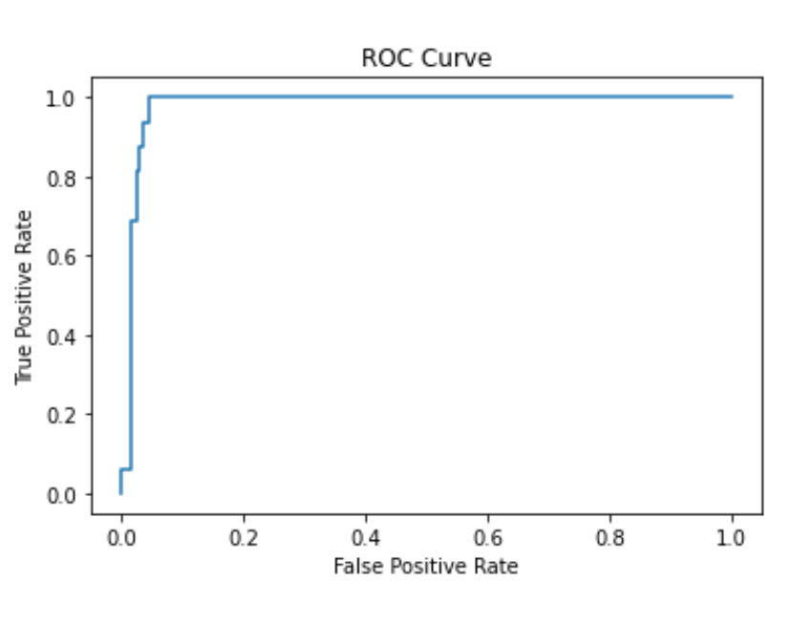

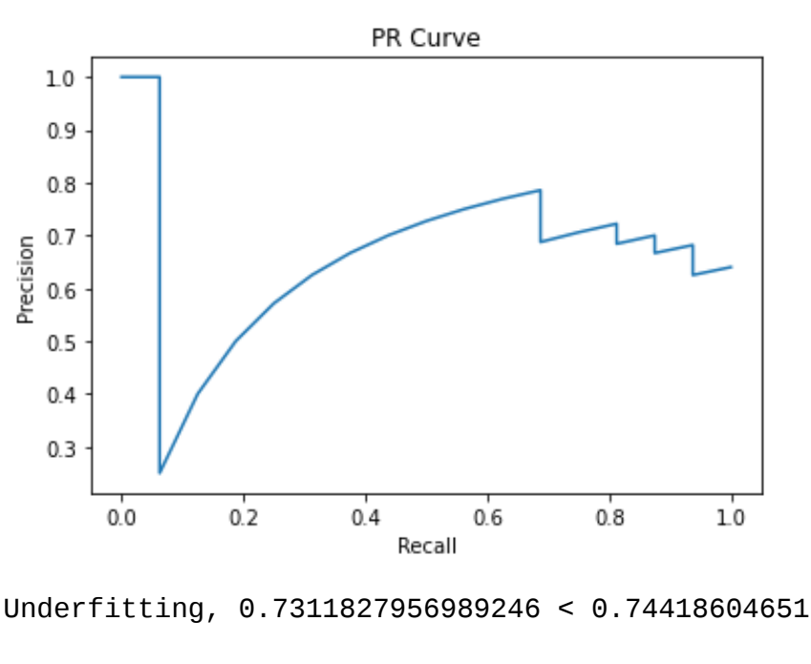

```
Underfitting, 0.7311827956989246 < 0.7441860465116279
```

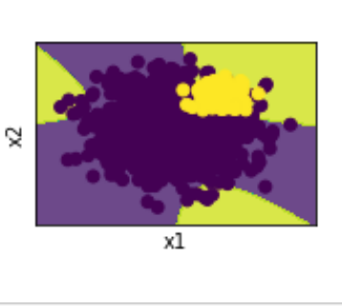

In [16]:
```python
clf = NuSVC(nu=0.1, kernel="poly", probability = True, degree = 4)
clf.fit(X1_train, y1_train)
metrics1(y1_test, clf.predict(X1_test), probs=clf.predict_proba(X1_test
))
overfitting(clf, X1_train, y1_train, X1_test, y1_test)
plot_dec(X1, Y1, clf, print_vectors=False)
```

```
Confusion Matrix:
 [[173  31]
 [  4  12]]
Precision score:  0.27906976744186046
Recall score:  0.75
F1 score:  0.4067796610169491
AUC score: 0.1332720588235294
```

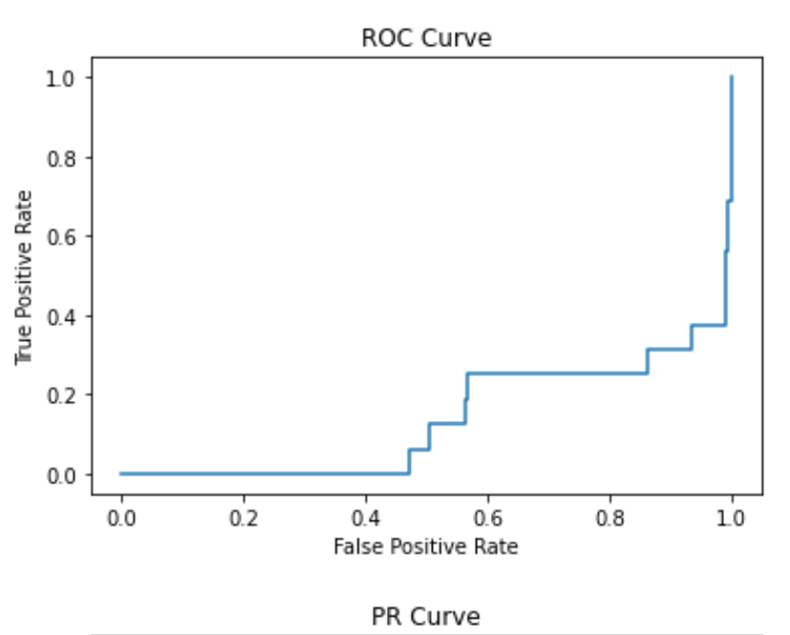

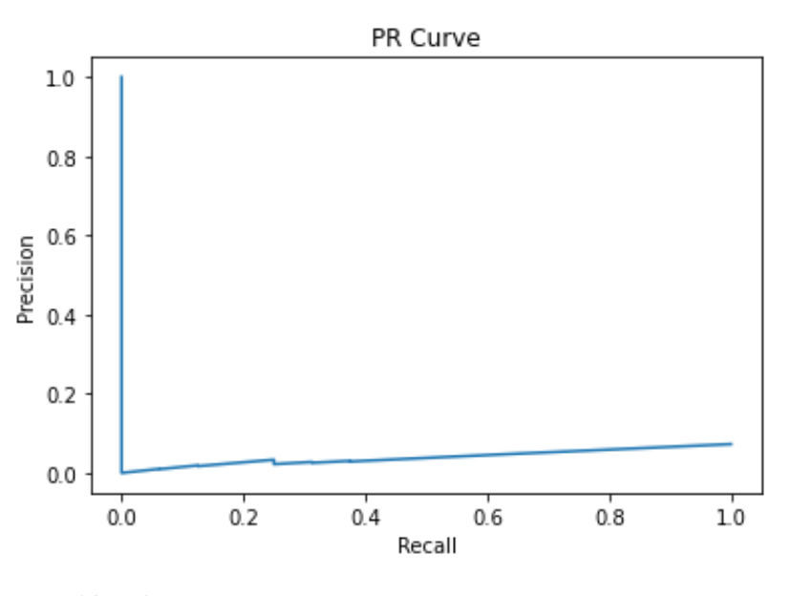

```
Overfitting 0.44621513944223107 >0.4067796610169491
```

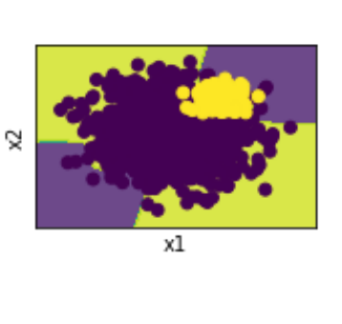

make_blobs dataset SVC

In [17]:
```python
clf_t = SVC(kernel="poly", probability = True, class_weight = 'balanced'
)
clf_t.fit(X1_train, y1_train)
metrics1(y1_test, clf_t.predict(X1_test), probs=clf_t.predict_proba(X1_t
est))
overfitting(clf_t, X1_train, y1_train, X1_test, y1_test)
plot_dec(X1, Y1, clf_t, print_vectors=False)
```

```
Confusion Matrix:
 [[184  20]
 [  0  16]]
Precision score:  0.4444444444444444
Recall score:  1.0
F1 score:  0.6153846153846153
AUC score: 0.9862132352941176
```

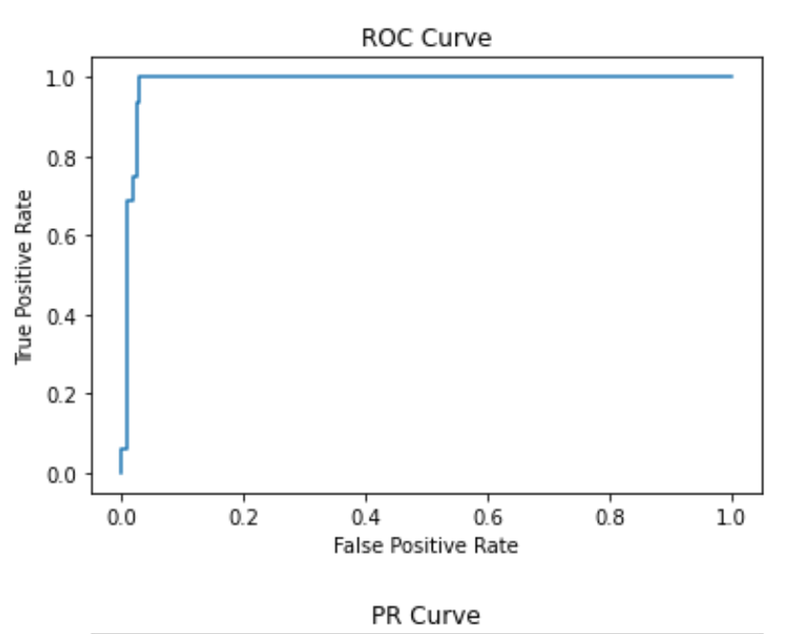

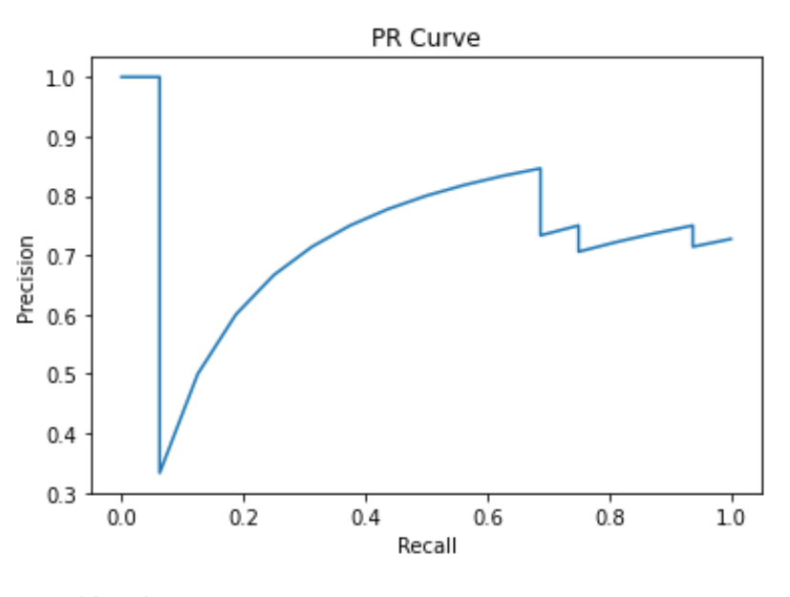

```
Overfitting 0.7655502392344498 >0.6153846153846153
```

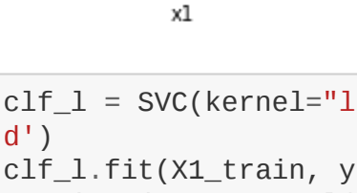

In [18]:
```python
clf_l = SVC(kernel="linear", probability = True, class_weight = 'balance
d')
clf_l.fit(X1_train, y1_train)
metrics1(y1_test, clf_l.predict(X1_test), probs=clf_l.predict_proba(X1_t
est))
overfitting(clf_l, X1_train, y1_train, X1_test, y1_test)
plot_dec(X1, Y1, clf_l, print_vectors=False)
```

```
Confusion Matrix:
 [[176  28]
 [  0  16]]
Precision score:  0.36363636363636365
Recall score:  1.0
F1 score:  0.5333333333333333
AUC score: 0.9770220588235294
```

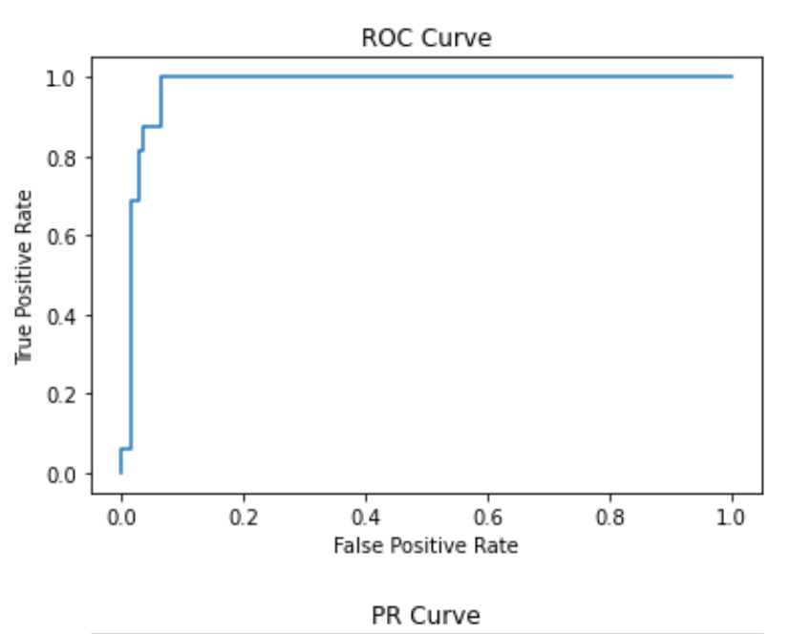

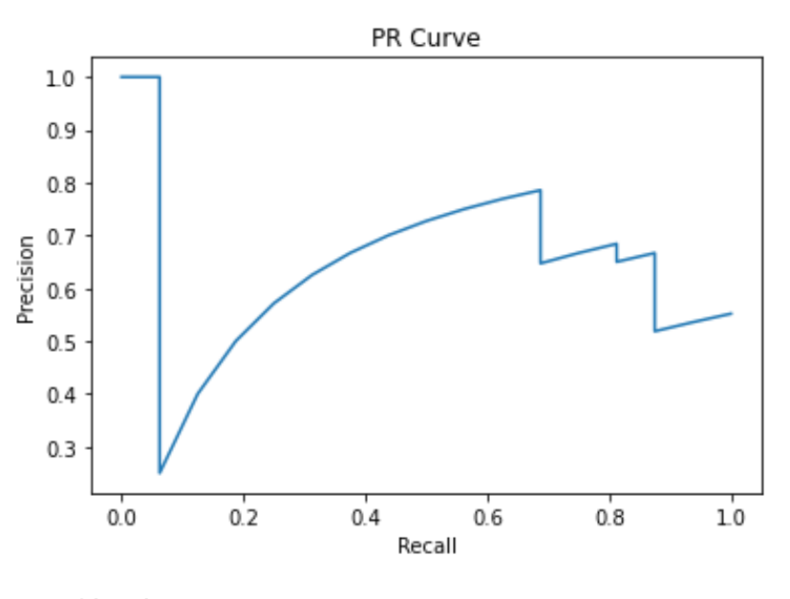

```
Overfitting 0.6612244897959183 >0.5333333333333333
```

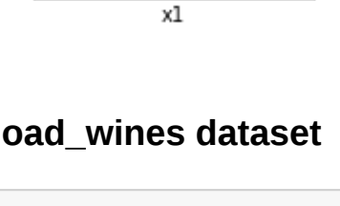

load_wines dataset

In [19]:
```python
from sklearn.metrics import classification_report
```

In [20]:
```python
def metrics2(true, predict):
    #критерії якості для кожної моделі
    print("Confusion Matrix:\n", confusion_matrix(true, predict))
    print("\n", classification_report(true, predict))
```

In [21]:
```python
def overfitting2(clf, X_train, y_train, X_test, y_test):
    clf.fit(X_train, y_train)
    train_f1 = f1_score(y_train, clf.predict(X_train), average='micro')
    test_f1 = f1_score(y_test, clf.predict(X_test), average='micro')
    if train_f1 > test_f1:
        print(f"Overfitting {train_f1} >{test_f1}")
    else:
        print(f"Underfitting, {train_f1} < {test_f1}")
```

load_wines dataset NuSVC

In [22]:
```python
for nu in np.arange(0, 1, 0.1):
     clf = NuSVC(nu=nu, kernel="poly", probability = True, degree = 3)
     try:
         clf.fit(X2_train, y2_train)
     except ValueError as e:
         print("nu {} not feasible".format(nu))
```

```
nu 0.0 not feasible
nu 0.9 not feasible
```

In [23]:
```python
clf = NuSVC(nu=0.7, kernel="poly", probability = True, degree = 3)
clf.fit(X2_train, y2_train)
metrics2(y2_test, clf.predict(X2_test))
overfitting2(clf, X2_train, y2_train, X2_test, y2_test)
```

```
Confusion Matrix:
 [[12  2  0]
 [ 0 14  0]
 [ 0  2  6]]

               precision    recall  f1-score   support

           0       1.00      0.86      0.92        14
           1       0.78      1.00      0.88        14
           2       1.00      0.75      0.86         8

    accuracy                           0.89        36
   macro avg       0.93      0.87      0.89        36
weighted avg       0.91      0.89      0.89        36

Underfitting, 0.7605633802816902 < 0.8888888888888888
```

In [24]:
```python
clf = NuSVC(nu=0.7, kernel="poly", probability = True, degree = 4)
clf.fit(X2_train, y2_train)
metrics2(y2_test, clf.predict(X2_test))
overfitting2(clf, X2_train, y2_train, X2_test, y2_test)
```

```
Confusion Matrix:
 [[ 9  5  0]
 [ 0 14  0]
 [ 0  3  5]]

               precision    recall  f1-score   support

           0       1.00      0.64      0.78        14
           1       0.64      1.00      0.78        14
           2       1.00      0.62      0.77         8

    accuracy                           0.78        36
   macro avg       0.88      0.76      0.78        36
weighted avg       0.86      0.78      0.78        36

Underfitting, 0.6901408450704225 < 0.7777777777777778
```

load_wines dataset SVC

In [25]:
```python
clf_w = SVC(kernel="poly", probability = True, class_weight = 'balanced'
)
clf_w.fit(X2_train, y2_train)
metrics2(y2_test, clf_w.predict(X2_test))
overfitting2(clf_w, X2_train, y2_train, X2_test, y2_test)
```

```
Confusion Matrix:
 [[14  0  0]
 [ 0 10  4]
 [ 1  4  3]]

               precision    recall  f1-score   support

           0       0.93      1.00      0.97        14
           1       0.71      0.71      0.71        14
           2       0.43      0.38      0.40         8

    accuracy                           0.75        36
   macro avg       0.69      0.70      0.69        36
weighted avg       0.74      0.75      0.74        36

Underfitting, 0.6901408450704225 < 0.75
```

In [26]:
```python
clf = SVC(kernel="linear", probability = True, class_weight = 'balanced'
)
clf.fit(X2_train, y2_train)
metrics2(y2_test, clf.predict(X2_test))
overfitting2(clf, X2_train, y2_train, X2_test, y2_test)
```

```
Confusion Matrix:
 [[14  0  0]
 [ 0 14  0]
 [ 0  0  8]]

               precision    recall  f1-score   support

           0       1.00      1.00      1.00        14
           1       1.00      1.00      1.00        14
           2       1.00      1.00      1.00         8

    accuracy                           1.00        36
   macro avg       1.00      1.00      1.00        36
weighted avg       1.00      1.00      1.00        36

Underfitting, 0.9929577464788732 < 1.0
```

9. Настроїти гіперпараметри nu, degree, C за допомогою перехресної перевірки. Настроїти гіперпараметр probability за допомогою перехресної перевірки. Для кожної навчальної вибірки вибрати найкращу модель.

In [27]:
```python
parameter_candidates_nu = [
  {'nu': [0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1], 'degree': [1,
2, 3, 4], 'probability':[True, False]}]

parameter_candidates = [
  {'C': [0.01, 0.1, 1, 10, 100]}]
```

make_blobs dataset

In [29]:
```python
clf1_n = GridSearchCV(estimator=NuSVC(), param_grid=parameter_candidates
_nu, n_jobs=-1)
clf1_n.fit(X1_train, y1_train)
print(f"Best parameters: {clf1_n.best_params_}")
print(f"Best score: {clf1_n.best_score_}")
```

```
Best parameters: {'degree': 1, 'nu': 0.1, 'probability': True}
Best score: 0.9670454545454547
```

In [30]:
```python
clf1 = GridSearchCV(estimator=SVC(), param_grid=parameter_candidates, n_
jobs=-1)
clf1.fit(X1_train, y1_train)
print(f"Best parameters: {clf1.best_params_}")
print(f"Best score: {clf1.best_score_}")
```

```
Best parameters: {'C': 10}
Best score: 0.9670454545454547
```

load_wines dataset

In [31]:
```python
clf2_w = GridSearchCV(estimator=SVC(), param_grid=parameter_candidates,
n_jobs=-1)
clf2_w.fit(X2_train, y2_train)
print(f"Best parameters: {clf2_w.best_params_}")
print(f"Best score: {clf2_w.best_score_}")
```

```
Best parameters: {'C': 100}
Best score: 0.7187192118226602
```

In [32]:
```python
clf2 = GridSearchCV(estimator=NuSVC(), param_grid=parameter_candidates_n
u, n_jobs=-1)
clf2.fit(X2_train, y2_train)
print(f"Best parameters: {clf2.best_params_}")
print(f"Best score: {clf2.best_score_}")
```

```
Best parameters: {'degree': 1, 'nu': 0.4, 'probability': True}
Best score: 0.8233990147783251
```

10. Навчити моделі на підмножинах навчальних даних. Оцінити, наскільки розмір навчальної множини впливає на якість моделі.

In [33]:
```python
from sklearn.model_selection import learning_curve
```

make_blobs dataset

In [33]:
```python
train_sizes1, train_scores1, test_scores1 = learning_curve(clf_l, X1_tes
t, y1_test, train_sizes=np.arange(1, 188), cv=7, n_jobs=-1)
```

In [34]:
```python
train_sizes2, train_scores2, test_scores2 = learning_curve(clf1, X1_test
, y1_test, train_sizes=np.arange(1, 188), cv=7, n_jobs=-1)
```

In [35]:
```python
_, axes = plt.subplots(1, 2, figsize=(15,5))

axes[1].plot(train_sizes2, np.mean(test_scores2, 1), color='red', label=
'test_score')
axes[1].plot(train_sizes2, np.mean(train_scores2, 1), color='blue', labe
l='train_score')
axes[1].hlines(np.mean([train_scores2[-1], test_scores2[-1]]), train_siz
es2[0], train_sizes2[-1], color='grey', linestyle='dashed')
axes[1].legend(loc=0)
axes[1].set_title('GridSearchCV model', size='x-large')

axes[0].plot(train_sizes1, np.mean(test_scores1, 1), color='red', label=
'test_score')
axes[0].plot(train_sizes1, np.mean(train_scores1, 1), color='blue', labe
l='train_score')
axes[0].hlines(np.mean([train_scores1[-1], test_scores1[-1]]), train_siz
es1[0], train_sizes1[-1], color='grey', linestyle='dashed')
axes[0].legend(loc=0)
axes[0].set_title('Default model', size='x-large')
```

Out[35]:
```
Text(0.5, 1.0, 'Default model')
```

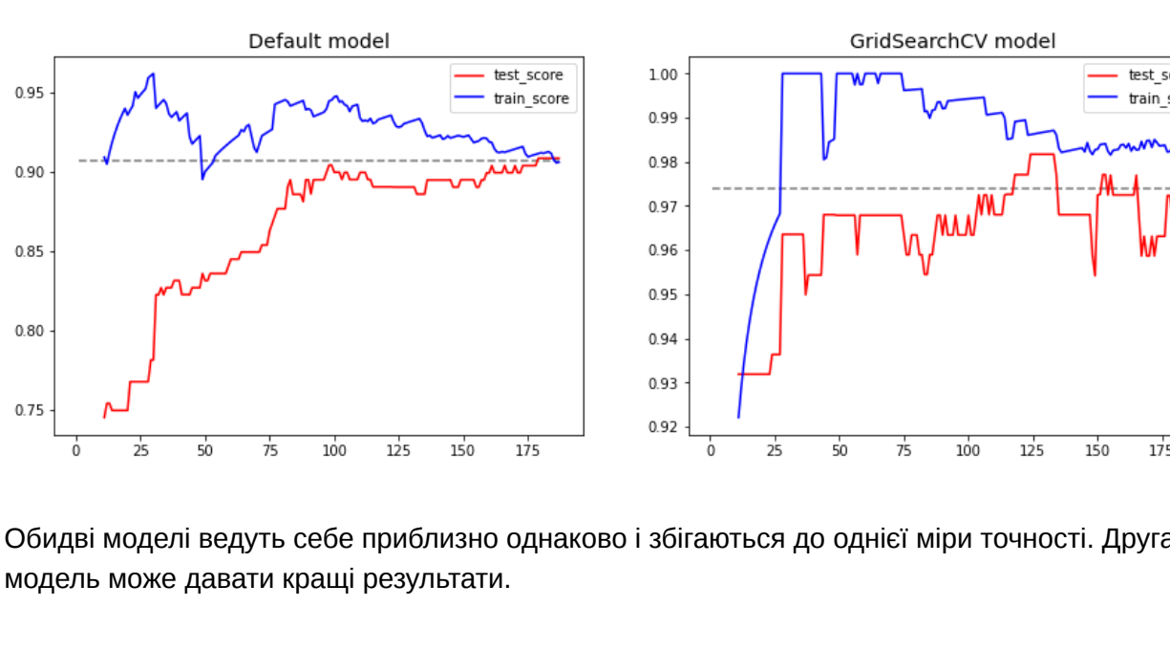

Обидві моделі ведуть себе приблизно однаково і збігаються до однієї міри точності. Друга модель може давати кращі результати.

load_wines dataset

In [39]:
```python
train_sizes1, train_scores1, test_scores1 = learning_curve(clf_w, X2_tes
t, y2_test, train_sizes=np.arange(1, 30), cv=7, n_jobs=-1)
```

In [40]:
```python
train_sizes2, train_scores2, test_scores2 = learning_curve(clf2_w, X2_te
st, y2_test, train_sizes=np.arange(1, 30), cv=7, n_jobs=-1)
```

In [41]:
```python
_, axes = plt.subplots(1, 2, figsize=(15,5))

axes[1].plot(train_sizes2, np.mean(test_scores2, 1), color='red', label=
'test_score')
axes[1].plot(train_sizes2, np.mean(train_scores2, 1), color='blue', labe
l='train_score')
axes[1].hlines(np.mean([train_scores2[-1], test_scores2[-1]]), train_siz
es2[0], train_sizes2[-1], color='grey', linestyle='dashed')
axes[1].legend(loc=0)
axes[1].set_title('GridSearchCV model', size='x-large')

axes[0].plot(train_sizes1, np.mean(test_scores1, 1), color='red', label=
'test_score')
axes[0].plot(train_sizes1, np.mean(train_scores1, 1), color='blue', labe
l='train_score')
axes[0].hlines(np.mean([train_scores1[-1], test_scores1[-1]]), train_siz
es1[0], train_sizes1[-1], color='grey', linestyle='dashed')
axes[0].legend(loc=0)
axes[0].set_title('Default model', size='x-large')
```

Out[41]:
```
Text(0.5, 1.0, 'Default model')
```

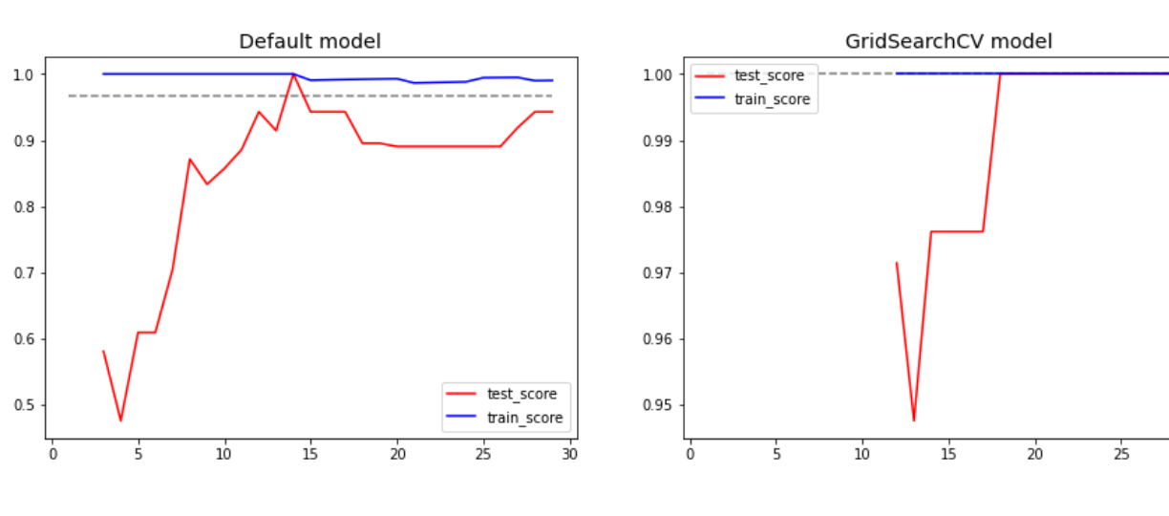

Бачимо, що крива навчання для Default model стає близькою до кривої перевірки при певному значенні розміру навчальної множини. Додавання нових навчальних прикладів не тільки істотно не покращують результати, але й відбувається погіршення. Поліпшити оцінку кривої навчання, яка вже зійшлася, можна лише використанням GridSearchCV model.

In [ ]: